

# MarkLens 졸업프로젝트 1학기 최종 보고서

도형 및 도형+문자 결합상표 시각 유사도 분석 시스템

깃허브 주소: <https://github.com/davinida/marklens>

|       |                               |
|-------|-------------------------------|
| 보고 범위 | 지난 진행 보고서(Phase 1 중간) 이후 ~ 현재 |
| 담당    | 최다빈, 정현수, 배지원                 |
| 팀 구성  | 최다빈, 정현수, 배지원                 |
| 작성일   | 2026년 6월 11일                  |
| 소속    | 건국대학교 컴퓨터공학부                  |

## 1. 요약

이번 보고 기간 동안 MarkLens는 Phase 1에서 완성한 머신러닝 검색 엔진을 토대로, 실제 상표 데이터를 다루고 외부에서 사용할 수 있는 웹 백엔드까지 갖춘 시스템으로 확장되었다. 지난 보고서가 "엔진을 만들었다"였다면, 이번 보고서는 "그 엔진이 실제 등록상표 100건으로 동작하고, 웹 API 형태로 호출 가능해졌다"로 요약된다.

**핵심 성과:** 다섯 가지 작업을 순차적으로 완료하였다.

- **위험도 등급 모듈(Phase 2-A):** 검색 결과를 4 단계 등급으로 변환하는 비즈니스 로직을 구현.
- **KIPRIS 실데이터 파이프라인(Phase 2-D):** 특허청 KIPRIS 등록상표 공보 데이터 100 건을 가공하여 검색 가능한 형태로 변환.
- **검색 인덱스 구축:** 실제 상표 로고 100 장으로 검색 인덱스를 생성하고, 검색,결합,등급 산출의 전체 흐름을 검증.
- **FastAPI 백엔드(Phase 2-B):** 이미지를 업로드하면 유사 상표를 검색해 등급과 함께 돌려주는 웹 API 를 구현.
- **설계 결정 정리:** 프로젝트 전반의 핵심 결정 사항을 문서화하여 팀 내 기준을 확립.

현재 시점에서 MarkLens는 "로고 이미지를 입력하면, 시각적으로 유사한 선행 등록상표를 찾아 위험도 등급과 함께 제시하는" 백엔드 시스템이 실제로 동작하는 상태이다. 남은 1학기 과제는 사용자가 직접 이용하는 화면(Phase 3)의 구현이다.

## 2. Phase 1 요약 — 머신러닝 검색 엔진

Phase 2를 이해하기 위한 토대로서, 지난 보고서 이후 마무리된 Phase 1의 전체 모습을 간략히 정리한다. Phase 1의 목표는 "이미지를 입력하면 유사한 이미지를 찾아내는" 머신러닝 검색 엔진을 만드는 것이었다. 세부 코드 단위가 아니라, 무엇을 만들었고 어떻게 동작하는지를 중심으로 서술한다.

### 2.1. 엔진의 동작 원리

MarkLens 검색 엔진은 두 개의 핵심 모듈로 이루어진다. 첫째는 이미지를 "숫자 벡터"로 변환하는 모듈이고, 둘째는 그 벡터들 사이에서 가장 비슷한 것을 빠르게 찾아내는 모듈이다.

- **이미지 → 벡터 변환:** OpenCLIP(ViT-B/32) 모델을 사용한다. CLIP은 약 4억 쌍의 이미지·텍스트로 학습된 모델로, 이미지를 512개의 숫자로 이루어진 벡터로 바꾼다. 이 벡터는 단순한 픽셀 값이 아니라 이미지의 시각적·의미적 특징을 담는다.
- **벡터 → 유사 검색:** FAISS 라이브러리로 벡터들을 인덱스에 저장하고, 입력 벡터와 가장 가까운 벡터들을 찾는다. 두 벡터가 가까울수록 두 이미지가 시각적으로 유사하다는 의미이다.

핵심 가설의 검증: 빨강·파랑·회색 단색 이미지로 실험한 결과, CLIP은 단순 색상 거리가 아니라 의미적 유사성을 본다는 점이 확인되었다. 이는 "색이 달라도 모양이 같으면 가깝게, 색이 같아도 모양이 다르면 멀게" 판단한다는 뜻으로, 상표 유사도 판단에 적합한 성질이다.

### 2.2. Phase 1 완료 범위

Phase 1은 다음 모듈과 스크립트로 구성되며, 모두 검증을 마쳤다.

| 구성 요소        | 역할                            |
|--------------|-------------------------------|
| embedding.py | 이미지를 512차원 CLIP 벡터로 변환        |
| search.py    | FAISS 인덱스 생성·저장·로드 및 유사 벡터 검색 |

|                |                             |
|----------------|-----------------------------|
| preprocess.py  | 다양한 형식의 입력 이미지를 일관된 형태로 정리  |
| build_index.py | 이미지 폴더로부터 검색 인덱스를 생성하는 스크립트 |
| test_search.py | 검색 동작을 확인하는 스크립트            |

Phase 1 시연에서는 유명 브랜드 로고 6종과 그 변형(모방) 로고 3종을 사용하여, 변형 로고를 입력했을 때 원본 로고를 정확히 찾아내는 것을 100% 적중률로 확인하였다. 다만 이 단계의 데이터는 시연용으로 직접 수집한 소수 샘플이었고, 실제 등록상표 데이터로의 확장이 Phase 2의 출발점이 되었다.

### 3. Phase 2-A — 위험도 등급 모듈

Phase 1의 검색 엔진은 "유사도 점수"라는 숫자만 돌려준다. 그러나 사용자에게 필요한 것은 숫자가 아니라 "이 상표를 출원해도 괜찮은가"에 대한 판단이다. Phase 2-A는 검색 결과를 사람이 이해할 수 있는 위험도 등급으로 변환하는 모듈(scoring.py)을 구현한 작업이다.

#### 3.1. 4 단계 등급 체계

검색 결과를 다음 네 단계의 등급 중 하나로 분류한다.

| 등급       | 의미                              |
|----------|---------------------------------|
| 주의 필요    | 유사한 선행 상표가 존재하여 출원 시 충돌 가능성이 높음 |
| 검토 권장    | 유사 가능성이 있어 추가 검토가 필요함           |
| 특정 위험 없음 | 두드러지게 유사한 선행 상표가 발견되지 않음        |
| 비교적 안전   | 유사한 선행 상표가 발견되지 않음              |

"특정 위험 없음"이라는 표현은 의도적으로 신중하게 선택되었다. 시스템이 유사 상표를 찾지 못했더라도 그것이 "안전하다"는 보장은 아니므로, 단정적인 표현 대신 "현재 데이터 기준 두드러진 위험이 없다"는 정직한 표현을 사용한다.

### 3.2. 판정 방식 — 유사도와 격차

등급 판정은 두 가지 정보를 함께 본다. 하나는 가장 유사한 상표의 유사도 점수이고, 다른 하나는 1위와 2위 결과 사이의 격차이다.

- **유사도 점수:** 입력 이미지와 가장 비슷한 선행 상표가 얼마나 닮았는지를 나타낸다.
- **격차(separability):** 1 위 결과가 다른 후보들보다 얼마나 두드러지게 유사한지를 나타낸다. 격차가 크면 1 위가 명확한 위협이고, 격차가 작으면 "비슷한 후보가 여럿이라 판정이 모호한" 상황이다.

두 정보를 위에서부터 차례로 검사하여 4단계 등급 중 하나로 분류한다. 예를 들어 유사도가 매우 높고 격차도 충분히 크면 "주의 필요"로, 유사도는 어느 정도 높지만 격차가 작으면 아래 등급으로 내려가는 식이다.

### 3.3. 등급 판정 경계값

각 등급은 아래의 경계 숫자를 기준으로 나뉜다. 유사도 경계 3개와 격차 경계 2개, 총 5개의 값을 사용한다.

| 경계값            | 값    | 역할                                    |
|----------------|------|---------------------------------------|
| 유사도 — 주의 필요 기준 | 0.75 | 가장 유사한 상표의 유사도가 이 이상이면 '주의 필요' 후보     |
| 유사도 — 검토 권장 기준 | 0.55 | 유사도가 이 이상이면 '검토 권장' 후보                |
| 유사도 — 위협 구분 기준 | 0.45 | 유사도가 이 이상이면 '특정 위협 없음', 미만이면 '비교적 안전' |
| 격차 — 주의 필요 기준  | 0.15 | '주의 필요'로 판정되려면 1·2위 격차가 이 이상이어야 함     |
| 격차 — 검토 권장 기준  | 0.04 | '검토 권장'으로 판정되려면 1·2위 격차가 이 이상이어야 함    |

이 다섯 개의 경계값은 확정된 기준이 아니라 임시값이다. Phase 1 시연에 쓰인 9장의 데이

터에서 역으로 계산해 정한 값으로, 코드에도 "임시값, 데이터 확보 후 튜닝 예정"으로 명시되어 있다. 실제로 KIPRIS 100건으로 검색해 보니 후보 간 격차가 전반적으로 좁게 나타나, 향후 100건 이상의 데이터 분포를 분석하여 경계값을 조정할 계획이다.

### 3.4. 모호 케이스 경고

등급과 별개로, 판정이 미덥지 않은 상황을 사용자에게 알리는 경고 장치를 두었다. 구체적으로는 가장 유사한 상표의 유사도가 검토 권장 기준(0.55) 이상으로 높은데도, 1위와 2위의 격차가 검토 권장 격차 기준(0.04)보다 작은 경우에 경고가 발동한다.

이는 "많은 후보가 여럿이라 1위 하나를 확정적인 위협으로 단정하기 어려운" 상황을 뜻한다. 이때 시스템은 등급과 함께 "경쟁 후보가 많아 판정이 모호하므로 전문가 확인을 권장한다"는 경고를 덧붙인다. KIPRIS 100건 검증에서 이 경고가 실제로 자주 발동하였는데, 이는 시스템 결함이 아니라 데이터 특성상 후보들이 서로 비슷하게 나오는 상황을 시스템이 정직하게 알리는 정상 동작이다.

### 3.5. 판정 요소의 확장 계획

현재 등급 판정은 시각 유사도라는 하나의 축만 사용한다. 그러나 상표의 유사 여부는 본래 여러 측면에서 함께 판단되며, 위험도 모듈은 처음부터 이러한 요소를 추가로 받아들일 수 있는 구조로 설계되었다. 향후 다음 요소들을 단계적으로 통합하여 판정 정확도를 높일 계획이다.

- **외관(시각) 유사도:** 로고가 시각적으로 닮았는지. 현재 구현된 축이다.
- **호칭(발음) 유사도:** 상표를 소리 내어 읽었을 때 닮았는지. 결합상표의 문자 부분에 적용된다.
- **관념(의미) 유사도:** 상표가 떠올리게 하는 의미가 닮았는지.
- **상품 분류:** 두 상표가 같거나 유사한 상품·서비스 분류에서 쓰이는지. 같은 업종일수록 충돌 위험이 크다.

이처럼 여러 요소를 종합하면 단일 시각 점수만 쓸 때보다 실제 상표 심사 기준에 가까운 판단이 가능하다. 현재의 위험도 모듈은 그 통합 구조의 첫 단계에 해당한다.

## 4. Phase 2-D — KIPRIS 실데이터 파이프라인

Phase 1까지의 데이터는 시연용으로 직접 모은 소수의 로고였다. 실제로 의미 있는 상표 검색을 하려면 특허청에 등록된 진짜 상표 데이터가 필요하다. Phase 2-D는 특허청 KIPRIS의 등록 상표 공보 데이터를 확보하고, 검색 엔진이 사용할 수 있는 형태로 가공한 작업이다.

### 4.1. 데이터 확보

KIPRIS에서 도형 상표 및 도형+문자 결합상표를 대상으로, 등록 상태인 상표 100건의 데이터를 신청하여 확보하였다. 확보한 데이터는 두 종류로 구성된다. 하나는 각 상표의 로고 견본이 담긴 PDF 파일 100개이고, 다른 하나는 상표명·출원인·분류 정보 등이 담긴 텍스트 파일들이다.

### 4.2. 데이터 가공 — 두 가지 산출물

확보한 원본 데이터를 검색에 쓸 수 있도록 두 가지 산출물로 가공하였다.

- **로고 이미지 추출:** 각 PDF에는 실제 로고 외에 특허청 양식 요소(태극 로고, 머리글 등)가 함께 들어 있다. 100개 PDF 전체에서 반복적으로 나타나는 양식 요소를 식별해 제외하고, 실제 로고만 골라 PNG 이미지 100장으로 추출하였다.
- **메타데이터 통합:** 여러 텍스트 파일에 흩어진 상표 정보(출원번호, 상표명, 출원인, 비엔나 분류 코드, 상품 분류 등)를 출원번호를 기준으로 하나의 통합 데이터 파일(kipris\_metadata.json)로 합쳤다.

| 가공 작업     | 결과                           |
|-----------|------------------------------|
| 도형 상표 필터링 | 100건 전부 도형 관련 상표로 확인 (제외 0건) |
| 로고 이미지 추출 | 100건 전부 추출 성공 (100/100)      |
| 메타데이터 통합  | 100건의 상표 정보를 단일 파일로 통합       |
| 정합성 검사    | 이미지와 메타데이터가 100% 일치 확인       |

### 4.3. 데이터 처리 방침

KIPRIS 상표 데이터는 각 상표권자의 저작물이며, 데이터 신청 시 명시한 이용 범위가 있다. 이에 따라 원본 데이터와 가공 산출물(이미지, 메타데이터)은 깃 저장소에 올리지 않고 별도로 관리하기로 하였다. 코드와 팀이 작성한 문서는 깃허브로, 저작권이 있는 데이터는 공유 드라이브와 추출 스크립트를 통해 팀원이 각자 확보하는 방식이다.

## 5. KIPRIS 검색 인덱스 구축

Phase 2-D에서 준비한 로고 100장을, Phase 1에서 만든 인덱스 생성 도구로 실제 검색 인덱스로 변환하였다. 이로써 시연용 9장 규모였던 검색 대상이 실제 등록상표 100건으로 확장되었다.

### 5.1. 인덱스 생성과 검증

로고 100장을 모두 벡터로 변환하여 검색 인덱스(kipris.faiss)를 생성하였다. 100건 전부 정상 처리되었다. 이어서 검색이 실제로 의미 있게 동작하는지 확인하기 위해, 검색 결과를 상표 상세 정보 및 위험도 등급과 연결하는 검증 스크립트(kipris\_search.py)를 작성하였다.

이 스크립트는 "이미지 검색 → 결과를 상표 정보와 결합 → 위험도 등급 산출"의 전체 흐름을 한 번에 수행한다. 시연용 로고를 입력해 검증한 결과, 세 단계가 끊김 없이 이어지는 것을 확인하였다. 이 스크립트는 이후 Phase 2-B 백엔드가 따를 처리 흐름의 청사진 역할을 하였다.

### 5.2. 인덱스 관리 방침



검색 인덱스는 원본 이미지만 있으면 언제든지 다시 생성할 수 있는 산출물이다. 따라서 데이터가 늘어나면 인덱스를 같은 이름으로 다시 생성(재빌드)하는 방침을 정하였다. 인덱스 파일명에 데이터 개수를 넣지 않고 고정된 이름을 사용함으로써, 인덱스를 사용하는 상위 코드를 데이터 갱신 때마다 수정할 필요가 없도록 하였다.

## 6. Phase 2-B — FastAPI 백엔드

지금까지의 검색 기능은 명령어로만 실행할 수 있었다. Phase 2-B는 이 기능을 외부에서 호출할 수 있는 웹 API(백엔드)로 구현한 작업이다. FastAPI 프레임워크를 사용하였다.

### 6.1. 제공하는 기능 — 두 개의 엔드포인트

| 엔드포인트        | 역할                                      |
|--------------|-----------------------------------------|
| POST /search | 이미지 파일을 업로드하면, 유사한 선행 상표 목록과 위험도 등급을 반환 |
| GET /health  | 서버가 정상 동작 중이고 검색 엔진이 준비되었는지 확인 (헬스 체크)  |

검색 결과로 나온 상표의 로고 이미지는, 별도의 정적 이미지 주소(/images)를 통해 제공된다. 응답에는 이미지 주소만 담기고, 화면이 그 주소로 이미지를 불러오는 방식이다.

### 6.2. 핵심 설계

- **시작 시 1 회 로딩:** CLIP 모델과 검색 인덱스는 용량이 크고 로딩에 시간이 걸린다. 따라서 서버가 시작될 때 한 번만 메모리에 올리고, 이후 모든 요청이 이를 재사용한다. 검증 결과 두 번째 요청부터는 1 초 미만으로 응답하였다.
- **입력 검증:** 업로드된 파일이 실제로 유효한 이미지인지를 파일 내용 기준으로 검사한다. 파일 형식, 크기 상한, 손상 여부, 이미지 치수를 확인하며, 문제가 있으면 적절한 오류 응답을 돌려준다. 확장자만 믿지 않고 실제로 이미지를 열어 확인하는 방식이다.

- **응답 데이터:** 응답에는 등급·유사 상표 목록·상표 상세 정보·데이터셋 안내를 충분히 담는다. 이 중 무엇을 사용자에게 보여줄지는 화면(Phase 3)이 결정하도록 하여, 백엔드와 화면의 역할을 분리하였다.

### 6.3. 동작 검증

정상 동작, 오류 처리, 이미지 제공, 경계 상황을 포함한 8가지 검증 항목을 모두 통과하였다. 잘못된 파일(텍스트 파일, 빈 파일 등)을 업로드했을 때 적절한 오류 응답이 돌아오는 것까지 확인하였다.

| 검증 항목         | 결과                      |
|---------------|-------------------------|
| 정상 검색 요청      | 통과 — 등급·결과·이미지 주소 정상 반환 |
| 헬스 체크         | 통과 — 엔진 준비 상태 정상 보고     |
| 잘못된 파일 형식     | 통과 — 적절한 오류 응답          |
| 빈 파일 / 경계값 입력 | 통과 — 적절한 오류 응답          |
| 로고 이미지 제공     | 통과 — 정적 주소로 이미지 정상 제공   |

## 7. 주요 설계 결정

이번 보고 기간 동안 내린 주요 설계 결정을 정리한다. 이 결정들은 별도의 설계결정기록 문서로도 관리되고 있다.

- **위험도는 다요소 통합 구조로:** 위험도 모듈을 처음부터 시각 외의 요소(호칭·관념 유사도, 상품 분류)를 추가로 받아들일 수 있는 구조로 설계하였다(상세는 3 장 참조). 단일 지표가 아닌 확장 가능한 판정 체계를 지향한다.
- **결과 화면은 3 층 구조로:** 1 층은 등급과 권장 행동, 2 층은 가장 유사한 선행 상표 비교, 3 층은 유사도 수치 등 상세 정보(접힘)로 구성하기로 하였다.

- **정직한 표현 원칙:** 시스템은 "등록 가능"을 단정하지 않으며, 법률 자문에 해당하는 판단은 제공하지 않는다. 유사 상표를 못 찾은 경우에도 "안전"이 아닌 "특정 위협 없음"으로 표현한다.
- **계층 분리:** 머신러닝 엔진, 비즈니스 로직, 웹 API, 화면을 명확히 분리하여, 한 부분의 변경이 다른 부분에 영향을 주지 않도록 하였다.

## 8. 새로운 다축(Multi-Axis) 위험도 평가 시스템 설계 (구현 예정)

초기 위험도 등급(3장)이 시각 유사도라는 단일 축에 의존했던 것과 달리, 본 장에서는 상표법의 유사 판단 원리를 정면으로 반영한다. 상표법에서 두 상표가 "유사하다"는 것은 단순히 외관이 닮았다는 의미가 아니라, 일반 수요자가 상품의 출처를 오인·혼동할 우려가 있다는 의미이다. 그리고 그 혼동 여부는 외관·호칭·관념의 세 요소를 종합하여 판단되며, 특히 우리가 주로 다루는 문자+도형 결합상표는 판례상 문자 부분의 호칭으로 인식·기억되는 경우가 많다. 사람들이 상표를 부르고 기억하며 검색하는 기준이 결국 "어떻게 부르는가(호칭)"이기 때문이다. 따라서 호칭을 중심 축으로 삼고 외관을 보조 축으로 재배치하는 다음의 다축 구조를 설계하였다.

기존의 구조적 취약점을 혁신적으로 극복하기 위해, 상표법상의 삼요소(외관, 호칭, 관념) 및 거래 실태(상품 분류)를 계량화하여 독립된 4가지 판단 축으로 분리 연산하는 '다축 위험도 평가 시스템'을 새롭게 정립하였다.

### 8.1. 시스템 입력 — 세 가지 입력과 그 이유

다축 평가를 수행하기 위해 시스템은 사용자로부터 다음 세 가지를 입력받는다.

- ① **로고 이미지:** 외관(시각) 유사도 판단에 사용한다. 기존과 동일한 입력이다.

② **상표명(텍스트)**: 호칭(발음) 및 관념(의미) 유사도 판단에 사용한다. 사용자가 직접 입력한다.

③ **지정상품/서비스**: 상품 건련성 판단에 사용한다. 사용자가 쉬운 상품명으로 검색·선택하면 시스템이 유사군 코드로 변환한다.

입력을 세 가지로 제한한 데에는 분명한 이유가 있다. 본 서비스의 대상 사용자는 변리사 같은 전문가가 아니라 일반인·소상공인이며, 핵심 가치는 "전문 지식이 없어도 누구나 쉽게 판단"할 수 있게 하는 것이다. 예컨대 도형 분류 체계인 비엔나 코드처럼 전문적인 정보까지 사용자가 직접 입력하게 하면 서비스의 진입 장벽이 높아져 아무도 사용하지 않게 된다. 따라서 사용자가 부담 없이 제공할 수 있는 최소한의 입력(이미지·상표명·지정상품)만 받되, 그로부터 외관·호칭·관념·상품 건련성이라는 최대한의 분석을 이끌어내는 것을 설계 원칙으로 삼는다.

| 판단 축        | 데이터 형태 및 입력                   | 핵심 산출 로직                                         |
|-------------|-------------------------------|--------------------------------------------------|
| 호칭 유사도 (X1) | 이미지를 512차원 CLIP 벡터로 변환        | G2P 변환 후 한글 자모 분해 기반 가중치 편집 거리(Edit Distance) 계산 |
| 외관 유사도 (X2) | FAISS 인덱스 생성·저장·로드 및 유사 벡터 검색 | OpenCLIP 기반 벡터 추출 및 코사인 유사도 산출                   |
| 관념 유사도 (X3) | 다양한 형식의 입력 이미지를 일관된 형태로 정리    | Word2Vec / Sentence-BERT 임베딩을 통한 단어 간 의미적 상동성 분석 |
| 상품 건련성 (X4) | 이미지 폴더로부터 검색 인덱스를 생성하는 스크립트   | 특허청 고시 유사군 코드 매핑 후 자카드 유사도 기반 중복도 연속 계산          |

## 8.2. 호칭 유사 판단의 법리 — 대법원 판례의 알고리즘화

호칭 유사 판단은 주관적으로 보이지만, 대법원 판례가 비교적 명확한 기준을 제시한다. 아래 다섯 가지 판례 법리를 계산 가능한 규칙으로 옮기는 것이 본 호칭 알고리즘(X1)의 핵심 설계

근거이다.

① **호칭이 가장 중요:** 광고 선전 매체의 광범위한 보급에 따라 문자상표의 유사 여부는 칭호가 가장 중요하다는 판례에 따라, 호칭을 다축 평가의 중심 축으로 설계한다.

② **짧은 상표의 첫음절 강세:** 짧은 음절로 구성된 문자상표에서 수요자는 첫음절을 강하게 호칭하려는 경향이 있다는 판례를 반영하여, 음절 수가 적을수록 어두(첫음절) 불일치에 더 큰 가중치를 부여한다.

③ **여러 호칭 중 하나만 유사해도 유사:** 하나의 상표에서 둘 이상의 호칭을 생각할 수 있는 경우 그중 하나의 호칭이 타인의 상표와 유사하면 두 상표가 유사하다는 판례에 따라, 한 상표명에서 가능한 여러 발음을 생성한 뒤 상대 상표와의 유사도 중 최댓값을 채택한다.

④ **외국어 상표는 국내식 발음으로:** 외국어로 이루어진 상표의 호칭은 우리나라 거래자·수요자가 자연스럽게 발음하는 바에 따라 정해진다는 판례에 따라, 영문 상표명을 한국식 발음(한글 표기)으로 변환한 뒤 비교한다.

⑤ **영문+한글 병기 시 한글 우선:** 상표가 영문과 그 한글 표기로 병기된 경우 원칙적으로 한글 표기에 따라 호칭한다는 판례에 따라, 한글이 병기되어 있으면 한글 발음을 기준으로 호칭 유사도를 산출한다.

### 8.3. X1 호칭 유사도 — 개요

대법원 판례 기준을 반영하여 청각적 혼동 가능성을 수치화한다. 영문 상표명의 경우 국내 거래자가 자연스럽게 발음하는 한글 표기로 변환하는 G2P(Grapheme-to-Phoneme) 전처리를 수행하며, 문자가 병기된 경우 한글 발음을 최우선으로 채택한다. 또한 수요자가 상표의 첫 음절에 강세를 두어 기억한다는 판례에 따라, 문자열 비교 시 첫 음절의 불일치에 강한 페널티를 부여하는 변형된 편집 거리 알고리즘을 코어 로직으로 구축한다.

## 8.4. X4 상품 견련성의 연속적 수치화

상품의 견련성을 "같은 류(類)이면 1, 다른 류이면 0"으로 단순화해서는 안 된다. 상표법상 상품의 유사성은 단절적인 일치/불일치가 아니라 정도(degree)의 문제이기 때문이다. 상품 분류 체계인 1~45류는 경계가 거칠어, 같은 류 안에도 서로 거리가 먼 상품이 섞여 있고 다른 류에 속하더라도 거래 실정상 밀접하게 연관된 상품이 있다. 이를 보완하기 위해 특허청이 "실제로 혼동될 만큼 가까운 상품끼리" 더 세밀하게 묶어 둔 분류인 유사군 코드(예: S0101, S1312)를 활용한다. 이 정보는 우리 메타데이터에 이미 포함되어 있으며, 사용자는 코드를 알 필요 없이 쉬운 상품명을 선택하면 시스템이 해당 유사군 코드로 변환한다.

상품 분류체계인 1~45류의 거친 경계를 보완하기 위해 특허청의 세부 분류인 유사군 코드(예: S0101)를 내부 데이터베이스와 연동한다. 두 상표가 지닌 유사군 코드 집합 간의 자카드 계수를 산출함으로써, 업종이 완벽히 일치하는 경우(1.0)부터 밀접한 파생 업종(0.5), 전혀 무관한 업종(0.0)까지의 스펙트럼을 연속형 변수로 정밀하게 획득한다.

## 8.5. 판단 축별 핵심 구현 알고리즘 및 파이프라인

기존에 완성된 외관 유사도(X2)의 CLIP 기반 FAISS 벡터 검색 엔진을 재활용함과 동시에, 새롭게 도입된 3가지 판단 축(X1, X3, X4)을 시스템적으로 산출하기 위한 구체적인 구현 파이프라인은 다음과 같다.

### 8.5.1. 호칭 유사도(X1) 도출 — G2P 기반 자모 분해 및 가중치 편집 거리

- 발음 정규화 (G2P): 입력된 상표명에 영문이 포함되거나 한영이 혼용된 경우, 파이썬 기반의 한국어 G2P(Grapheme-to-Phoneme) 라이브러리를 활용하여 우리나라 거래자가 자연스럽게 발음하는 한글 표기로 일괄 변환한다.

- 자모 분해: 유니코드 연산을 통해 변환된 한글을 '초성-중성-종성' 단위의 자모 벡터로 완전히 분해한다. (예: '스타' -> 'ㅅ-ㅏ-ㅌ-ㅏ')
- 알고리즘 구현: 두 자모 벡터 간의 Levenshtein Distance 를 계산하되, 대법원 판례의 첫 음절 강세 기준을 반영한다. DP(Dynamic Programming) 행렬 연산 시, 인덱스가 첫 음절에 해당하는 경우 불일치 페널티(Penalty) 비용을 일반 문자의 2 배 이상으로 부여하는 커스텀 편집 거리 함수를 구현하여 유사도(0~100)를 산출한다.

### 8.5.2. 관념 유사도(X3) 도출 — 사전학습 언어모델(PLM) 임베딩

- 의미 벡터 추출: 상표명이 지닌 의미론적 거리를 측정하기 위해 Word2Vec 또는 Sentence-BERT(SBERT) 등 사전학습된 자연어 처리 모델을 도입한다.
- 유사도 산출: 'King'과 '왕'처럼 표기와 발음은 다르지만 관념이 동일한 경우를 잡아내기 위해, 두 상표명의 텍스트 임베딩 벡터 간의 코사인 유사도를 계산한다. 이를 통해 형태적 비교의 한계를 의미론적 비교로 보완한다.

### 8.5.3. 상품 건련성(X4) 도출 — 유사군 코드 기반 자카드 계수

- 코드 매핑: 사용자가 입력한 일반 상품명을 특허청 내부 세부 분류 체계인 '유사군 코드(예: S0101, S1312 등)' 데이터베이스와 매핑하여 각각의 코드 집합(Set)을 추출한다.
- 연속적 수치화: 두 상표의 유사군 코드 집합 A와 B에 대하여 자카드 유사도를 계산한다. 단순 일치 여부가 아닌 교집합의 크기를 활용함으로써, 업종이 완벽히 일치하는 경우(1.0)부터 밀접하게 연관된 파생 업종(예: 0.5), 전혀 무관한 업종(0.0)까지의 스펙트럼을 연속형 독립변수로 정밀하게 획득한다.

## 9. 머신러닝 기반 통계적 최적화 모델 구현 예정

추출된 4가지 독립 변수(X1, X2, X3, X4)를 연구원의 주관적 기준이나 단순 산술평균으로 결합하는 것은 과학적 근거가 결여된다. 따라서 MarkLens는 실제 법적 분쟁 데이터인 '특허법원 심결 데이터'를 기반으로 각 변수의 가중치를 자동 최적화하는 머신러닝 최적화 레이어를 도입하고자 한다.

### 9.1. 로지스틱 회귀 모델 수식화

사전 도출된 4대 평가지표를 입력 변수로 받아, 최종 아웃풋을 사용자가 직관적으로 이해할 수 있는 0~100% 사이의 출처 혼동 위험 확률(P)로 변환하기 위해 로지스틱 회귀 모델을 설계하였다.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4)}}$$

여기서 X1은 호칭 점수, X2는 외관 점수, X3은 관념 점수, X4는 상품 점수이며, 각  $\beta$ 는 해당 판단 축이 최종 혼동 위험에 미치는 상대적 영향력을 나타내는 회귀계수(가중치)이다.

### 9.2. 최대우도추정법(MLE)을 통한 가중치( $\beta$ ) 최적화 및 목적함수

임의의 임시 가중치 대신, 실제 법원의 심결 데이터와 모델의 예측값 간의 오차를 최소화하는 방향으로 파라미터를 추정한다. 이를 위해 통계적 최적화 기법인 Maximum Likelihood Estimation을 사용하여 아래의 Log-Likelihood Function 혹은 음의 로그 우도 함수(Log Loss)를 목적함수로 설정한다.



$$J(\beta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(P(x_i)) + (1 - y_i) \log(1 - P(x_i))]$$

컴퓨터로 Newton-Raphson 알고리즘이나 Gradient Descent를 통해 오차 함수의 표면을 따라가며 최저점을 탐색하고, 최종적으로 오차가 가장 적은 상태의 최적 가중치 셋  $\hat{\beta}$ 을 산출한다.

이 통계적 최적화의 핵심 의미는, 사용자에게 제시되는 위험도 퍼센트가 "연구자가 임의로 정한 값"이 아니라 "실제 심결 데이터로부터 학습된 근거 있는 값"이 된다는 점이다. 어느 정도의 수치가 위험하고 어느 정도가 안전한지를 실제 유사·비유사 판단 사례에 비추어 결정함으로써, 단순히 CLIP이 산출한 시각 유사도 점수를 그대로 보여주는 것과 본질적으로 구별되는, MarkLens 고유의 위험도 산출 모델을 완성한다.

## 10. 향후 계획

### 10.1. 방향 전환에서 덜어낸 것 — 폐기한 접근

다축 구조로의 전환은 새로운 판단 축을 더하는 것과 동시에, 초기 계획 중 일부를 의도적으로 덜어내는 결정을 포함한다. 다음 두 가지는 더 이상 사용하지 않는다.

- OCR(이미지 속 문자 자동 인식) 폐기: 초기에는 결합상표 이미지에서 문자 부분을 OCR로 자동 추출하려 하였다. 그러나 OCR은 글자를 잘못 인식할 가능성이 있는 반면, 사용자가 상표명을 직접 입력하면 100% 정확하다. 불확실한 자동 추출을 확실한 직접 입력으로 대체함으로써 정확도를 높였으므로, 이는 기능 후퇴가 아니라 개선이다.
- 비엔나 코드 예측 모델 폐기: 사용자가 올린 로고에는 비엔나 코드(도형 분류)가 부여되어 있지 않으므로, 이를 활용하려면 이미지로부터 비엔나 코드를 예측하는 모델이 필요하다.

그러나 수백 종에 이르는 코드를 안정적으로 정확히 예측하는 것은 그 자체로 거대한 별도 연구 과제이며, 비용과 정확도 측면에서 부담이 크다. 따라서 비엔나 코드 예측은 제외한다. (다만 DB에 이미 부여되어 있는 등록상표의 비엔나 코드 자체는 메타데이터로 보존되어 화면 참고 정보로 활용 가능하다.)

## 10.2. 필수 구현 과제

- 호칭 유사도 알고리즘
- 관념 유사도 알고리즘
- 상품 건련성 알고리즘
- 머신러닝으로 가중치 최적화
- Frontend 최소 기능 구현
  - 이미지 업로드 화면: 사용자가 로고 이미지를 업로드하면, 그 이미지로 유사 상표를 검색하는 화면을 구현한다
  - 결과 화면은 3층 구조로: 1층은 등급과 권장 행동, 2층은 가장 유사한 선행 상표 비교, 3층은 유사도 수치 등 상세 정보(접힘)
  - 결과 표시: 설계한 3층 구조에 따라 위험도 등급과 유사 상표 비교 결과를 표시
- 통합 및 데이터 확장
  - 백엔드 연동: Phase 2-B에서 만든 /search API와 정적 이미지 제공 기능을 활용한다.

## 10.3. 확장 구현 가능성

- RAG 기반 판례 제시(논문·판례를 넣어두고 관련 판례를 보여주는 AI 대화 인터랙션)
- 식별력 없는 상표 필터: 상표법상 보통명칭, 관용표장, 기술적 표장(상품의 성질·품질 등을 직

접 표시), 현저한 지리적 명칭, 흔한 성 또는 명칭, 간단하고 흔한 표장, 그 밖에 식별력 없는 표장은 그 자체로 등록받을 수 없다. 이러한 상표는 애초에 등록 가능성이 없어 선행상표와의 유사 판단 자체가 의미가 없으므로, 유사도 검색을 수행하기 전 단계에서 먼저 걸러내는 기능을 추가할 수 있다. (1학기에 폐기한 OCR 기능의 자리를 대체하는, 사용자에게 더 실질적으로 유용한 기능이다.)

- 도형의 관념 유사 판단: 도형이 떠올리게 하는 의미(예: 별·동물·왕관 등)의 유사를 다루는 확장이다. 다만 사용자에게 자신의 로고가 어떤 도형 분류에 속하는지까지 직접 고르게 하면 입력이 지나치게 복잡해져 "누구나 쉽게"라는 본 서비스의 취지에 어긋난다. 또한 판례상 도형상표는 외관이 주는 지배적 인상이 판단의 중심이므로, 현재 구현된 외관(X2) 축으로 핵심은 이미 다루어진다. 이러한 이유로 도형 관념은 1학기 범위에서 제외하고 향후 과제로 둔다.